

从线性分类器到多层感知机

课程：深度学习与计算机视觉

姓名：徐义涛 学号：U202314356 班级：种子2301班

实验日期：2026 年 10 月 2 日

摘要

本实验在 Fashion-MNIST 上比较线性 Softmax 分类器、两层无激活线性网络和单隐藏层 ReLU MLP，并通过 NumPy 手写反向传播与中心差分检查验证梯度实现。统一数据划分和训练条件后，三个模型的测试准确率分别为 $84.33\% \pm 0.11$ 、 $84.30\% \pm 0.20$ 和 $88.15\% \pm 0.20$ ，其中“ $\pm$ ”表示三个随机种子的样本标准差，单位为百分点。增加线性层没有带来明显的整体性能提升，而加入 ReLU 后，测试准确率较 Softmax 提高约 3.82 个百分点。针对两层线性模型的后期波动，仅将学习率从 0.01 降至 0.003，验证损失的后期相邻变化幅度降低 57.46%，但测试准确率仅提高约 0.06 个百分点。结果说明，应分别评价模型表达能力、优化稳定性与最终泛化性能。

1. 实验目标与数据划分

实验围绕三个问题展开：手写的反向传播是否正确；仅增加线性层能否改善分类；非线性激活与训练超参数分别会怎样影响结果。

Fashion-MNIST 包含 10 类服饰图像，每张图像为 28×28 灰度图。官方提供 60,000 张训练图像和 10,000 张测试图像。类别包括短袖上衣、长裤、套衫、连衣裙、外套、凉鞋、衬衫、运动鞋、包和短靴。数据说明见 [Fashion-MNIST 官方仓库](#)。

使用 NumPy 随机种子 42 打乱官方训练集索引，固定划分为 50,000 张训练图像和 10,000 张验证图像，保存索引后供所有模型复用。该划分为随机划分，不是分层抽样。像素值除以 255 缩放至 $[0, 1]$ ，并展平为 784 维向量，不使用数据增强或额外标准化。

训练集用于更新参数；验证集用于选择模型轮次和开展训练诊断；官方测试集在模型与诊断方案固定后才用于最终评价。每次运行均选取验证交叉熵最低的轮次，并列时取较早轮次。本文的“最佳模型”均指这一选择规则，不按测试准确率选择种子或轮次。

准确率为正确预测数与样本总数之比；交叉熵按样本平均。逐类召回率定义为：

$$\text{Recall}_c = \frac{C_{cc}}{\sum_j C_{cj}},$$

其中混淆矩阵 C 的行对应真实类别，列对应预测类别。测试集每类恰有 1,000 张图像，因此宏平均召回率与总体准确率相等。所有三次运行的标准差均按分母 $n - 1$ 计算，它反映固定划分上的训练随机性，不是置信区间。

2. 模型与受控训练设置

2.1 三种模型的差别

设批次大小为 B ，输入 X 是 $B \times 784$ 的实数矩阵，模型输出的类别分数 Z 是 $B \times 10$ 的实数矩阵。为与 NumPy 实现一致，以下使用样本按行排列的记号。

模型	类别分数的计算	网络结构	参数量
Softmax 分类器	$Z = XW + b$	784 $\rightarrow$ 10	7,850
两层线性，无激活	$Z = (XW_1 + b_1)W_2 + b_2$	784 $\rightarrow$ 256 $\rightarrow$ 10	203,530
ReLU MLP	$Z = \text{ReLU}(XW_1 + b_1)W_2 + b_2$	784 $\rightarrow$ 256 $\rightarrow$ ReLU $\rightarrow$ 10	203,530

两层无激活网络可合并为：

$$Z = X(W_1W_2) + (b_1W_2 + b_2) = X\widetilde{W} + \widetilde{b}.$$

因此，它对输入计算的类别分数仍是仿射映射。当前隐藏宽度 256 不会限制 784×10 有效权重矩阵的秩，两层模型与单层模型可表示相同的仿射映射集合。增加参数改变了参数化方式和优化过程，却没有引入新的非线性决策边界。

ReLU 定义为 $\max(0, z)$ ，其激活状态随输入变化，使网络能够学习分段线性的类别分数。比较两个参数量相同的两层模型，可以更直接地观察非线性激活的影响。

2.2 统一训练配置

配置项	设置
损失函数	平均多分类交叉熵
优化器	SGD，动量 0.9
学习率	0.01，训练过程中保持不变
批大小、轮数	128，30 轮，保留最后一个不足批次
隐藏宽度	两个两层模型均为 256
初始化	Xavier 均匀分布，gain=1；偏置为 0
正则化	weight decay=0，不使用 Dropout
其他策略	无数据增强、学习率调度或提前停止
训练种子	42、43、44
计算设置	CPU，4 线程，float32

每次模型训练前重新创建数据加载器，使用独立的随机数生成器控制打乱顺序。同一种子下，不同模型使用相同的逐批样本顺序；两个两层模型的初始权重和偏置也完全相同。三模型共完成 $3 \times 3 = 9$ 次训练、270 轮。

实验在 Apple M5、16 GB 内存的 macOS 环境中运行，主要依赖为 Python 3.11.16、PyTorch 2.14.1、Torchvision 0.29.1 和 NumPy 2.4.6。正式训练前，按当前实现测量 CPU 与 MPS 的完整轮次耗时，三个模型的单轮中位耗时之和分别为 0.957 秒和 3.518 秒，因此统一使用 CPU。此处计时包含训练、验证和轮末训练集评价，结论仅适用于当前小模型与批大小，不能推广为硬件峰值性能比较。

3. NumPy 前向传播、反向传播与梯度检查

3.1 前向传播与稳定的交叉熵

使用 NumPy 实现单隐藏层网络：

$$A = XW_1 + b_1, \quad H = \max(0, A), \quad Z = HW_2 + b_2.$$

对第 i 个样本，先将每个类别分数减去该样本的最大类别分数：

$$s_{ij} = z_{ij} - \max_k z_{ik}.$$

然后计算对数概率、概率和平均交叉熵：

$$\log p_{ij} = s_{ij} - \log \sum_k e^{s_{ik}}, \quad p_{ij} = e^{\log p_{ij}}, \quad L = -\frac{1}{B} \sum_{i=1}^B \log p_{i, y_i}.$$

减去同一样本的最大分数不会改变 Softmax 概率，却可以避免直接对大数取指数。损失直接从 $\log p$ 取值，避免先得到接近零的概率后再取对数。中间结果 X 、 y 、 A 、 H 、 P 缓存供反向传播使用。

3.2 手写梯度

令 Y 为标签的 one-hot 矩阵，Softmax 与交叉熵组合后的梯度为：

$$G = \frac{\partial L}{\partial Z} = \frac{P - Y}{B}.$$

沿计算图继续应用链式法则：

$$\begin{aligned} \frac{\partial L}{\partial W_2} &= H^\top G, & \frac{\partial L}{\partial b_2} &= \sum_i G_{i,:}, \\ D &= (GW_2^\top) \odot \mathbf{1}(A > 0), & \frac{\partial L}{\partial W_1} &= X^\top D, & \frac{\partial L}{\partial b_1} &= \sum_i D_{i,:}. \end{aligned}$$

偏置对同批所有样本共享，因此偏置梯度沿样本维求和。ReLU 在负半轴的梯度为 0，正半轴为 1；实现中在 0 处取 0。该部分不调用自动求导，也不使用 NumPy 训练完整数据集。

3.3 中心差分检查结果

对单个参数 θ_k ，数值梯度为：

$$g_k^{\text{num}} = \frac{L(\theta + \epsilon e_k) - L(\theta - \epsilon e_k)}{2\epsilon}.$$

为降低检查成本，采用 $784 \rightarrow 8 \rightarrow 10$ 的小网络和固定的 4 张训练图像，原始索引为 3493、57546、8815、19332。权重使用标准差为输入宽度平方根倒数的正态初始化，初始化种子为 42；参数抽样种子为 43。计算采用 float64， $\epsilon = 10^{-5}$ 。这一检查配置与正式训练配置不同，用于验证相同结构的前向和梯度公式。

每组参数最多抽查 20 个元素，通过条件为：

$$|g^{\text{ana}} - g^{\text{num}}| \leq 10^{-7} + 10^{-5} \max(|g^{\text{ana}}|, |g^{\text{num}}|).$$

相对误差另记为：

$$\frac{|g^{\text{ana}} - g^{\text{num}}|}{\max(10^{-12}, |g^{\text{ana}}| + |g^{\text{num}}|)}.$$

若扰动跨过 ReLU 折点则跳过该项，且扰动后恢复原参数。

参数	有效检查数	最大绝对误差	最大相对误差	失败 / 跳过
W_1	20	1.97×10^{-11}	1.89×10^{-9}	0 / 0
b_1	8	1.95×10^{-11}	4.95×10^{-9}	0 / 0
W_2	20	2.23×10^{-11}	7.06×10^{-9}	0 / 0
b_2	10	2.64×10^{-11}	1.60×10^{-10}	0 / 0

固定批次平均交叉熵为 2.30578687，58 个抽样元素全部通过。解析梯度与数值梯度在所检批次和参数上高度一致，为实现正确性提供了数值证据；抽样检查不能替代对所有参数、输入和边界情况的证明。

4. 三模型整体性能与学习曲线

4.1 非线性激活带来了主要的性能提升

下表中的验证与测试指标均由最低验证损失对应的模型计算。准确率以“均值 ± 样本标准差”报告，单位为 %；数值差异在正文中以百分点表示。

模型	验证准确率	测试准确率	测试交叉熵
Softmax	85.50 ± 0.09	84.33 ± 0.11	0.4441 ± 0.0009
两层线性，无激活	85.46 ± 0.09	84.30 ± 0.20	0.4417 ± 0.0018
ReLU MLP	89.17 ± 0.06	88.15 ± 0.20	0.3284 ± 0.0032

Softmax 与两层线性模型的测试准确率仅相差约 0.03 个百分点，未观察到增加线性层带来的整体优势。这与两者仿射表达能力相同的推导一致。不过，两层模型的优化目标对分解后的参数不再具有与单层模型相同的优化性质，所以训练轨迹、局部类别表现和最终参数不必一致。

ReLU MLP 相比 Softmax 和两层线性模型分别提高约 3.82、3.85 个百分点，同时降低交叉熵。两个两层模型参数量相同、初始参数相同，这一比较支持非线性激活在当前设置下具有实际作用。验证准确率整体高于测试准确率约 1 个百分点，也说明用于选模型的验证结果不宜直接当作最终泛化指标。

4.2 曲线显示表达能力差异与后期波动




图 1 三模型学习曲线。上排为交叉熵，下排为准确率；粗线表示三个种子的均值，细线表示各次运行。训练和验证曲线均用每轮结束时的固定模型计算，避免将逐批更新过程的损失与静态验证损失直接比较。

两个线性模型的验证损失较早进入平台区，后续训练改善有限。ReLU MLP 的训练损失持续下降，验证损失也降到更低水平，体现了更强的拟合能力。MLP 后期训练与验证之间的差距扩大，但验证表现仍有改善且伴随波动，不能仅凭差距扩大就断言出现持续恶化的过拟合。

部分种子的训练损失和验证损失会同步上升，尤其是两层线性模型种子 44 的最后一轮。这提示需要检查优化稳定性，相关单因素诊断见第 6 节。

5. 类别表现与典型错误

5.1 混淆集中在外形相近的上装类别

为避免根据测试表现选择展示对象，混淆矩阵和错误图固定使用预先指定的种子 42。




图 2 测试集混淆矩阵，种子 42。 行为真实类别，列为预测类别；数值为占该真实类别的百分比，对角线即该次运行的逐类召回率。三个面板使用相同的色标。

Softmax 的主要错误集中在套衫、外套、衬衫和短袖上衣之间。例如，1,000 张套衫中有 159 张被判为外套；1,000 张衬衫中，分别有 139、114、102 张被判为短袖上衣、外套和套衫。这些类别在低分辨率灰度图中具有接近的整体轮廓，分类可能需要更细的领口、袖型和纹理组合。

5.2 MLP 改善了困难类别，但衬衫仍是短板

下表汇总全部三个种子的召回率，单位为 %，每类测试样本数均为 1,000；它与图 2 的单种子结果口径不同。

类别	Softmax	两层线性	ReLU MLP
短袖上衣	79.93 ± 1.99	81.07 ± 0.25	84.13 ± 2.57
长裤	95.60 ± 0.53	96.00 ± 0.17	96.87 ± 0.15
套衫	72.67 ± 3.16	74.90 ± 1.71	77.23 ± 3.37
连衣裙	86.67 ± 0.65	86.20 ± 0.89	90.37 ± 1.48
外套	76.40 ± 2.69	70.70 ± 2.62	80.97 ± 4.67
凉鞋	92.73 ± 0.21	92.03 ± 0.91	95.17 ± 0.55
衬衫	57.87 ± 0.76	59.33 ± 2.80	69.60 ± 1.01
运动鞋	92.10 ± 0.50	93.13 ± 1.76	95.37 ± 1.36
包	94.43 ± 0.12	94.63 ± 0.46	96.13 ± 0.23
短靴	94.93 ± 0.50	95.00 ± 0.87	95.67 ± 0.75

MLP 的十类平均召回率均高于 Softmax，其中衬衫提高约 11.73 个百分点，是改善最明显的类别。但其衬衫召回率仍只有 69.60%，说明总体准确率提升并未消除相近类别之间的困难。长裤、鞋类和包的召回率普遍较高，其外形与其他类别的区分相对容易。

两个线性模型整体准确率接近，但类别间存在取舍。例如，两层线性模型的套衫召回率高于 Softmax，外套召回率则更低。这说明仅看总体准确率会掩盖错误分布的变化。

5.3 错误样例体现了改善与局限

先按 Softmax 错误计数选取前六个有向混淆类别对，再在每对中取原始测试索引最小的错误样本。三个模型对同一组图像进行配对展示，不按 MLP 是否纠正错误来挑选图片。



图 3 常见混淆对应的错误样例，种子 42。索引从 0 开始；括号内为预测类别的 Softmax 概率。样例用于解释错误形态，不代表全部错误的随机样本。

样本 117、20 和 263 分别被 Softmax 误判为外套、衬衫和衬衫，MLP 给出了正确类别，表明非线性特征组合能够修正部分相近服饰错误。不过，样本 40 被三个模型都判为短袖上衣，MLP 对错误类别仍给出 92.2% 的概率；样本 219 被两层线性模型正确分类，MLP 却误判为外套。由此可见，整体更优不意味着逐样本都更优，高预测概率也不等同于可靠保证。本实验没有进行额外的概率校准评估。

6. 单因素训练诊断：降低学习率改善稳定性

6.1 现象、假设与对照设计

原两层线性模型后期出现训练和验证损失同步波动。若只观察验证损失上升，容易将其归因于过拟合；同步上升则提示参数更新可能偏离了当前较好的区域。因此，在对照训练前提出假设：**学习率 0.01 可能使后期更新幅度偏大，降低学习率有望减轻波动，但可能减慢收敛。**

仅将两层线性模型的学习率改为 0.003，保留其余训练配置、数据划分、三个种子、初始化和批次顺序不变，仍训练 30 轮。假设、改变项与评价规则在对照训练前保存，未在观察测试结果后追加调参。诊断结果单独呈现，不替换第 4 节的统一配置比较。

预先采用第 21–30 轮的验证损失作为后期窗口，定义相邻变化幅度：

$$V = \frac{1}{9} \sum_{t=22}^{30} |L_{\text{val},t} - L_{\text{val},t-1}|.$$

同时考察静态训练损失的相邻变化、最低验证损失和准确率。V 包含波动与尚未消失的收敛趋势，不能解释为纯随机噪声的方差。

6.2 波动减小，性能改善有限




图 4 两层线性模型的学习率对照。 每列为同一种子的配对结果，上排为静态训练损失，下排为验证损失；灰色区间为第 21–30 轮。较小学习率的后期曲线总体更平稳，但前期损失下降更慢。

下表为三个种子的均值，准确率标准差以百分点计。

指标	学习率 0.01	学习率 0.003
后期验证损失相邻变化 V	0.00927 ± 0.00311	0.00394 ± 0.00141
后期静态训练损失相邻变化	0.00943 ± 0.00313	0.00390 ± 0.00163
最低验证损失	0.41635 ± 0.00206	0.41465 ± 0.00097
最佳验证模型准确率 (%)	85.46 ± 0.09	85.68 ± 0.21
最后一轮验证准确率 (%)	84.67 ± 0.96	85.59 ± 0.11
最佳验证模型的测试准确率 (%)	84.30 ± 0.20	84.36 ± 0.14

种子 42、43、44 的 V 分别下降 68.97%、39.12%、61.34%，方向一致。按两个条件的平均 V 计算，下降比例为 $1 - 0.00394353 / 0.00927041 = 57.46\%$ 。训练损失的变化也减小，支持降低学习率能够改善当前训练稳定性的判断。

代价是较小学习率收敛更慢：三个种子的最佳轮次从 14、20、25 推迟到 25、27、29。最佳验证准确率平均提高约 0.22 个百分点，但最终测试准确率只提高约 0.06 个百分点；因此，诊断的主要收益是稳定性改善，不能据此宣称泛化性能明显提高。

降低学习率并未改变网络仍为仿射映射的事实，也未使两层线性模型接近 ReLU MLP 的整体性能。这进一步区分了优化设置与模型表达能力各自的作用。

7. 结论与局限

- 1. **梯度实现得到数值验证。** 固定训练批次上的 58 项中心差分检查全部通过，最大绝对误差约为 2.64×10^{-11} ，支持手写前向与反向计算的一致性。
- 2. **层数增加需要结合非线性。** 两层无激活网络可合并为单个仿射映射，参数量虽明显增加，测试准确率仍与 Softmax 基线接近；在相同两层结构中加入 ReLU 后，测试准确率达到 88.15%。
- 3. **错误分析补充了总体指标。** 主要困难集中在外形相近的上装类别。MLP 改善了衬衫等困难类别，但仍会产生高置信度错误，也不是每张图像都优于线性模型。
- 4. **训练稳定性与泛化提升应分别判断。** 单独降低学习率使后期波动下降约 57%，但测试准确率变化很小，稳定的曲线本身不能替代最终性能评价。

实验只使用一个固定数据划分和三个训练种子，标准差仅反映这组设置内的随机差异。模型比较采用相同训练预算与超参数，有利于控制变量，但不等同于分别充分调参后的最优性能比较。梯度检查是有限抽样；错误样例按明确规则选取，但不能用于估计全部错误的发生比例。

附录：逐次结果与复现入口

A. 各次运行结果

所有准确率单位为 %。“选定轮次”按最低验证交叉熵确定。

模型 / 学习率	种子	选定轮次	验证准确率	测试准确率
Softmax / 0.01	42	28	85.48	84.46
Softmax / 0.01	43	28	85.60	84.25
Softmax / 0.01	44	30	85.43	84.29
两层线性 / 0.01	42	14	85.54	84.32
两层线性 / 0.01	43	20	85.48	84.49
两层线性 / 0.01	44	25	85.36	84.09
ReLU MLP / 0.01	42	30	89.14	88.22
ReLU MLP / 0.01	43	24	89.14	87.92
ReLU MLP / 0.01	44	28	89.24	88.31
两层线性 / 0.003	42	25	85.81	84.38
两层线性 / 0.003	43	27	85.78	84.49
两层线性 / 0.003	44	29	85.44	84.22

B. 配套材料说明

配套源代码包含数据加载、三模型定义、共用训练与评价流程、NumPy 梯度检查和绘图程序。README 提供环境配置、数据获取、运行命令及随机种子说明；结果文件保留逐轮指标、逐类评价和梯度检查明细，便于复核本文图表。

参考资料

1. 廖振宇：《从线性分类器到多层感知机》，2026 年秋季《深度学习与计算机视觉》课程实验说明。
2. Xiao, H., Rasul, K., & Vollgraf, R. (2017). [Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms](#).
3. Zalando Research. [Fashion-MNIST 官方数据与类别说明](#).